### Tabelle LALR

#### Costruzione delle tabelle di parsing LALR

#### Maria Rita Di Berardini

Dipartimento di Matematica e Informatica Università di Camerino mariarita.diberardini@unicam.it

### Metodo LALR

- Introduciamo l'ultimo metodo di costruzione di tabelle di parsing LR
- Nome: lookahead-LR abbreviato in LALR
- Questo metodo è usato spesso dato che le tabelle che si ottengono sono sensibilmente più piccole di quelle ottenute con l'LR canonico
- Le tabelle SLR e LALR per una data grammatica hanno sempre lo stesso numero di stati
- Per un linguaggio tipo il Pascal otteniamo una tabella con alcune centinaia di stati per un
- Per lo stesso linguaggio una tabella LR canonica ha alcune migliaia di stati

 Consideramo la grammatica utilizzata per illustrare la metodologia LR canonica:

$$S' \to S$$

$$S \to CC$$

$$C \to cC \mid d$$

- Alcuni insiemi di item LR(1) della collezione canonica per questa grammatica soddisfano un'interessante proprietà: stesso insieme di item LR(0) ma diverso simbolo di lookahead (la seconda componente)
- Ad esempio:  $I_4 = \{[C \rightarrow d \bullet, c/d]\} \text{ ed } I_7 = \{[C \rightarrow d \bullet, \$]\}$
- Osserviamo meglio il comportamento di questi due stati durante l'operazione di parsing
- La grammatica genera stringhe della forma  $c^n dc^m d$  con  $n, m \ge 0$



# Parsing della stringa ccdcd

	С	d	\$	S	$\mathcal{C}$
<i>S</i> <sub>0</sub>	<i>S</i> 3	<i>S</i> 4		1	2
$s_1$			ACC		
<b>s</b> 2	S6	S7			5
<b>s</b> 3	S3	S4			8
<i>S</i> <sub>4</sub>	R3	R3			
<i>S</i> <sub>5</sub>			R1		
<i>s</i> <sub>6</sub>	S6	S7			9
<i>S</i> <sub>7</sub>			R3		
<i>s</i> <sub>8</sub>	R2	R2			
<b>S</b> 9			R2		

Stack	Input	Azione
<i>S</i> <sub>0</sub>	ccdcd\$	shift S3
S <sub>0</sub> C S <sub>3</sub>	cdcd\$	shift S3
S <sub>0</sub> C S <sub>3</sub> C S <sub>3</sub>	dcd\$	shift S4
s <sub>0</sub> c s <sub>3</sub> c s <sub>3</sub> ds <sub>4</sub>	cd\$	red. $C \rightarrow d$
s <sub>0</sub> c s <sub>3</sub> c s <sub>3</sub> Cs <sub>8</sub>	cd\$	red. $C \rightarrow cC$
s <sub>0</sub> c s <sub>3</sub> Cs <sub>8</sub>	cd\$	red. $C \rightarrow cC$
$s_0 C s_2$	cd\$	shift S6
s <sub>0</sub> Cs <sub>2</sub> c s <sub>6</sub>	d\$	shift S7
s <sub>0</sub> Cs <sub>2</sub> c s <sub>6</sub> d s <sub>7</sub>	\$	red. $C \rightarrow d$
s <sub>0</sub> Cs <sub>2</sub> c s <sub>6</sub> C s <sub>9</sub>	\$	red. $C \rightarrow cC$
$s_0 Cs_2 Cs_5$	\$	red. $S \rightarrow CC$
$s_0 S s_1$	\$	acc

- Durante la lettura di un input  $c^n dc^m d$  il parser shifta nello stack il primo gruppo di c ed infine la prima d arrivando nello stato  $s_4$
- A questo punto il parser ordina una riduzione in base alla produzione  $C \rightarrow d$  se il prossimo simbolo input è una c o una d
- Giusto: una stringa della forma  $c^m d$ , con  $m \ge 0$  può cominciare sia con c che con d
- D'altra parte se la prima d è seguita dal \$ il parser deve segnalare un errore: la stringa ccd non appartiene al linguaggio generato dalla grammatica
- ullet Infatti il parser segnala un errore se nello stato  $s_4$  legge un \$



- Dopo la prima d il parser appila il secondo gruppo di c e quindi la seconda d entrando infine nello stato s<sub>7</sub>
- A questo punto il simbolo di input deve essere \$ altrimenti la stringa data non è nel linguaggio (errore)
- IL parser nello stato  $s_7$  ordina una riduzione in base alla produzione  $C \to d$  se il prossimo simbolo in input è il \$ e un errore se il prossimo simbolo in input è una c o una d

- Cosa succede se rimpiazziamo gli insiemi di item  $I_4 = \{[C \to d \bullet, c/d]\}$  ed  $I_7 = \{[C \to d \bullet, \$]\}$  con un unico insieme  $I_{47} = \{[C \to d \bullet, c/d/\$]\}$
- Le azioni dello stato corrispondente  $s_{47}$  sono "riduci per ogni simbolo in input"
- Dobbiamo modificare anche la goto tenendo conto del fatto che  $goto(I_0, d) = I_4$ ,  $goto(I_2, d) = I_7$ ,  $goto(I_3, c) = I_4$  e  $goto(I_6, c) = I_7$
- Otteniamo  $goto(I_0, d) = goto(I_2, d) = goto(I_3, c) = goto(I_6, c) = I_{47}$
- Il parser così modificato si comporta quasi allo stesso modo di quello originario
- Potrebbe ridurre in alcune circostanze in cui il parser originario avrebbe segnalato un errore, ad esempio ccd o ccdcdc
- L'errore viene rilevato in una fase successiva e comunque prima che venga shiftato il prossimo simbolo terminale sullo stack



# Parsing della stringa ccdcd

	С	d	\$	S	С
<i>s</i> <sub>0</sub>	S3	S47		1	2
$s_1$			ACC		
<b>s</b> <sub>2</sub>	S6	S47			5
<b>s</b> <sub>3</sub>	S3	S47			8
S <sub>47</sub>	R3	R3	R3		
<i>S</i> <sub>5</sub>			R1		
<i>s</i> <sub>6</sub>	S6	S47			9
<i>s</i> <sub>8</sub>	R2	R2			
<b>S</b> 9			R2		

Stack	Input	Azione
<i>S</i> <sub>0</sub>	ccdcd\$	shift S3
S <sub>0</sub> C S <sub>3</sub>	cdcd\$	shift S3
S <sub>0</sub> C S <sub>3</sub> C S <sub>3</sub>	dcd\$	shift S47
s <sub>0</sub> c s <sub>3</sub> c s <sub>3</sub> ds <sub>47</sub>	cd\$	red. $C \rightarrow d$
s <sub>0</sub> c s <sub>3</sub> c s <sub>3</sub> Cs <sub>8</sub>	cd\$	red. $C \rightarrow cC$
s <sub>0</sub> c s <sub>3</sub> Cs <sub>8</sub>	cd\$	red. $C \rightarrow cC$
$s_0 C s_2$	cd\$	shift S6
s <sub>0</sub> Cs <sub>2</sub> c s <sub>6</sub>	d\$	shift S47
$s_0 C s_2 c s_6 d s_{47}$	\$	red. $C \rightarrow d$
$s_0 C s_2 c s_6 C s_9$	\$	red. $C \rightarrow cC$
$s_0 Cs_2 Cs_5$	\$	red. $S \rightarrow CC$
$s_0Ss_1$	\$	acc

# Parsing della stringa ccd

	С	d	\$	S	С
<i>s</i> <sub>0</sub>	S3	S47		1	2
$s_1$			ACC		
<b>s</b> <sub>2</sub>	S6	S47			5
<b>s</b> 3	S3	S47			8
S <sub>47</sub>	R3	R3	R3		
<i>S</i> <sub>5</sub>			R1		
<i>s</i> <sub>6</sub>	S6	S47			9
<i>S</i> <sub>8</sub>	R2	R2			
<b>S</b> 9		·	R2		

Stack	Input	Azione
<i>s</i> <sub>0</sub>	ccd\$	shift S3
S <sub>0</sub> C S <sub>3</sub>	cd\$	shift S3
<i>s</i> <sub>0</sub> <i>c s</i> <sub>3</sub> <i>c s</i> <sub>3</sub>	d\$	shift S47
$s_0c s_3c s_3ds_{47}$	\$	red. $C \rightarrow d$
s <sub>0</sub> c s <sub>3</sub> c s <sub>3</sub> Cs <sub>8</sub>	\$	errore

### In generale

- Cerchiamo insiem di item con core comune
- Il core di un insieme di item LR(1) è determinato dall'insieme delle loro prime componenti; in generale è un insieme di item LR(0)
- E li fondiamo in un unico insieme
- Nell'esempio precedente gli insiemi  $I_4$  ed  $I_4$ , con core  $C \to d \bullet$ , vengono fusi in un unico item  $I_{47}$
- $I_3 = \{[C \to c \bullet C, c/d], [C \to \bullet cC, c/d], [C \to \bullet d, c/d]\}$  ed  $I_6 = \{[C \to c \bullet C, \$], [C \to \bullet cC, \$], [C \to \bullet d, \$]\}$  vengono fusi in  $I_{36} = \{[C \to c \bullet C, c/d/\$], [C \to \bullet cC, c/d/\$], [C \to \bullet d, c/d/\$]\}$
- $I_8 = \{[C \to cC \bullet, c/d]\}$  ed  $I_9 = \{[C \to cC \bullet, \$]\}$  vengono fusi in  $I_{89} = \{[C \to cC \bullet, c/d/\$]\}$



### La goto di insiemi accorpati

La goto di insiemi accorpati restituisce insiemi accorpati; esempio:

$$goto(I_3, C) = I_8$$
  
 $goto(I_6, C) = I_9 \implies goto(I_{36}, C) = I_{89}$   
 $goto(I_3, c) = I_3$   
 $goto(I_6, c) = I_6 \implies goto(I_{36}, c) = I_{36}$   
 $goto(I_3, d) = I_4$   
 $goto(I_6, d) = I_7 \implies goto(I_{36}, d) = I_{47}$ 

- Questo dipende essenzialmente dal fatto che il core di goto(I, X) è determinato dal core di I
- L'operazione di fusione degli insiemi di item con core comune comporta la creazione di una collezione canonica diversa e quindi la costruzione di una tabella diversa



### Conseguenze

- Supponiamo di avere una grammatica LR(1)
- La sua collezione canonica di item LR(1) non produce conflitti
- Se accorpiamo gli insiemi di item con core comune ci potremmo aspettare che i nuovi item producano dei conflitti
- In realtà non è così almeno per quanto rigurda i conflitti shift-reduce

## Conseguenze

- ullet Supponiamo di avere un coflitto shift-reduce in uno stato accorpato  $I_{jk}$
- La presenza di questo conflitto ci dice che  $I_{jk}$  deve contenere due item della forma:

$$[A \to \alpha \bullet, a]$$
  $action[s_{jk}, a] = \text{red. } A \to \alpha$   
 $[A \to \beta \bullet a\gamma, b]$   $action[s_{jk}, a] = \text{shift}$ 

- Se  $[A \to \alpha \bullet, a] \in I_{jk}$  allora  $[A \to \alpha \bullet, a]$  deve appartenere ad uno degli insiemi originari, diciamo  $I_i$
- Dato che  $I_{jk}$  è stato ottenuto fondendo insiemi con core comune  $I_j$  deve anche contenere un item della forma  $[A \to \beta \bullet a\gamma, c]$  (prima componente uguale, la seconda può anche essere diversa)
- Ma se i entrambi gli item  $[A \to \alpha \bullet, a]$  e  $[A \to \beta \bullet a\gamma, c]$  sono in  $I_j$ , allora lo stesso conflitto c'è anche sull'insieme di item LR(1) di partenza
- Il che contraddice l'ipotesi di partenza



## Conflitti reduce/reduce

È possibile che l'accorpamento provochi conflitti reduce/reduce;
 consideramo la seguente grammatica LR(1):

$$S' \rightarrow S$$
  
 $S \rightarrow aAd \mid bBd \mid aBe \mid bAe$   
 $A \rightarrow c$   
 $B \rightarrow c$ 

genera le stringhe acd, bcd, ace, bce

- Costruendo la collezione canonica LR(1) identifichiamo gli insiemi di item  $\{[A \to c \bullet, d], [B \to c \bullet, e]\}$  e  $\{[A \to c \bullet, e], [B \to c \bullet, d]\}$
- Che accorpati producono:  $\{[A \to c \bullet, d/e], [B \to c \bullet, d/e]\}$
- Conflitto reduce/reduce: sui simboli in input d ed e viene indicato di ridurre sia con  $A \rightarrow c$  che con  $B \rightarrow c$
- La grammatica è LR ma non LALR



### Costruzione della tabella LALR

- Esistono due metodi
- Il primo è basato sulla costruzione preliminare della collezione canonica LR(1)
- È il più semplice ma anche il più costoso
- Il secondo genera direttamente gli stati del parser LALR senza passare per gli stati del parser LR
- Vediamo solo la prima metodologia che si basa sull'accorpamento di insiemi di item LR(1) con core comune

## Algoritmo

- Input: una grammatica G' aumentata
- Output: la tabella di parsing LALR
- 1. Costruisci la collezione canonica di item LR(1)  $C = \{I_0, I_1, \dots, I_n\}$
- 2. Identifica e accorpa tutti gli insiemi di item con core comune. Il risultato di questa operazione è una nuova collezione  $C' = \{J_0, J_1, \dots, J_m\}$
- 3. I valori della tabella nella parte action per lo stato  $s_k$  sono costruiti a partire dall'insieme  $J_k$  utilizzando lo stesso algoritmo visto per la costruzione della tabella LR canonica. Se ci sono conflitti allora la grammatica non è LALR(1)



### Algoritmo

- 4. La parte goto della tabella è costruita come segue:
  - sia  $J_k$  l'unione di insiemi di item LR(1):  $J_k = I_1 \cup I_2 \cup \ldots \cup I_j$
  - dal fatto che  $l_1, l_2 \dots l_j$  sono stati accorpati in un unico insieme possiamo dedurre che  $l_1, l_2 \dots l_j$  hanno lo stesso core
  - e, quindi, anche  $goto(I_1, X), goto(I_2, X), \dots goto(I_j, X)$  hanno lo stesso core
  - sia K il core degli insiemi  $goto(I_1, X), goto(I_2, X), \dots goto(I_j, X)$
  - poniamo goto(J, X) = K

Riprendiamo la grammatica

$$S' \to S$$

$$S \to CC$$

$$C \to cC \mid d$$

• Abbiamo accorpato gli insiemi  $I_4$  e  $I_7$ ,  $I_3$  e  $I_6$  ed  $I_8$  e  $I_9$  ottenendo:

$$I_{47} = \{ [C \rightarrow d \bullet, c/d/\$] \}$$

$$I_{36} = \{ [C \rightarrow c \bullet C, c/d/\$], [C \rightarrow \bullet cC, c/d/\$], [C \rightarrow \bullet d, c/d/\$] \}$$

$$I_{89} = \{ [C \rightarrow cC \bullet, c/d/\$] \}$$
Inoltre:

Inoltre:

$$goto(I_{36}, C) = I_{89}$$
  
 $goto(I_{36}, c) = I_{36}$   
 $goto(I_{36}, d) = I_{47}$ 



## La tabella di parsing

	С	d	\$	S	С
<i>s</i> <sub>0</sub>	<i>S</i> 3	<i>S</i> 4		1	2
$s_1$			ACC		
<b>s</b> <sub>2</sub>	S6	S7			5
<b>s</b> 3	S3	S4			8
<i>S</i> <sub>4</sub>	R3	R3			
<i>S</i> <sub>5</sub>			R1		
<i>s</i> <sub>6</sub>	S6	S7			9
<i>S</i> <sub>7</sub>			R3		
<i>s</i> <sub>8</sub>	R2	R2			
<b>S</b> 9			R2		

	С	d	\$	S	C
<i>s</i> <sub>0</sub>	S36	S47		1	2
$s_1$			ACC		
<b>s</b> <sub>2</sub>	S36	S47			5
<i>s</i> <sub>36</sub>	S36	S47			98
S <sub>47</sub>	R3	R3	R3		
<i>S</i> <sub>5</sub>			R1		
<b>S</b> 89	R2	R2	R2		

### Considerazioni finali

- Se presentiamo al parser LALR una stringa sintatticamnte corretta (nel nostro esempio una stringa di ccdcd) esso esegue esattamente le stesse mosse del parser LR canonico
- Se presentiamo una stringa che non appartiene al linguaggio i due parser hanno un comportamento differente, ma entrambi segnalano l'errore
- Vedere l'esempio del parsing della stringa ccd qualche slide fa