

Traduzione guidata dalla sintassi

Attributi e definizioni guidate dalla sintassi

Maria Rita Di Berardini

Dipartimento di Matematica e Informatica
Università di Camerino
mariarita.diberardini@unicam.it

Introduzione

- Analisi sintattica: il flusso di token (analisi lessicale) viene raggruppato in frasi grammaticali rappresentate tramite alberi di derivazione di una grammatica libera da contesto.
- Questo tipo di rappresentazione intermedia ci permette di identificare operatori ed operandi delle espressioni e statements
- Costituisce l'input della fase di analisi semantica:
 - verifica dell'esistenza di eventuali errori semantici
 - acquisizione di informazioni sui tipi utilizzate nelle fasi successive del processo di compilazione
 - type checking
- Come possiamo definire la semantica ai costrutti dei linguaggi di programmazione?

Introduzione

- Consideriamo la grammatica per il linguaggio delle espressioni naturali:

$$\begin{aligned} E &\rightarrow E + T \mid E - T \mid T \\ T &\rightarrow T * F \mid T / F \mid F \\ F &\rightarrow (E) \mid \mathbf{number} \end{aligned}$$

- Definire la semantica di questo linguaggio significa definire il valore di ogni possibile espressione costruita applicando le produzioni della grammatica
- Associamo ad ogni non terminale della grammatica, e quindi ad ogni nodo del albero di derivazione per una data stringa, un attributo **val** che rappresenta appunto il suo valore: **E.val**, **T.val**, e così via
- A questo punto non ci resta che associare a ciascuna produzione della grammatica un regola, regola semantica, che ci dice come calcolare il valore di una espressione a partire da quello delle sue sottoespressioni

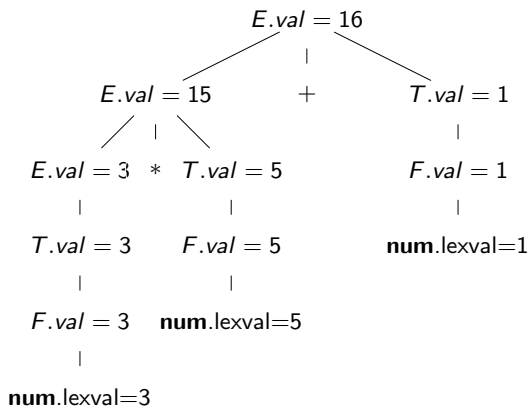
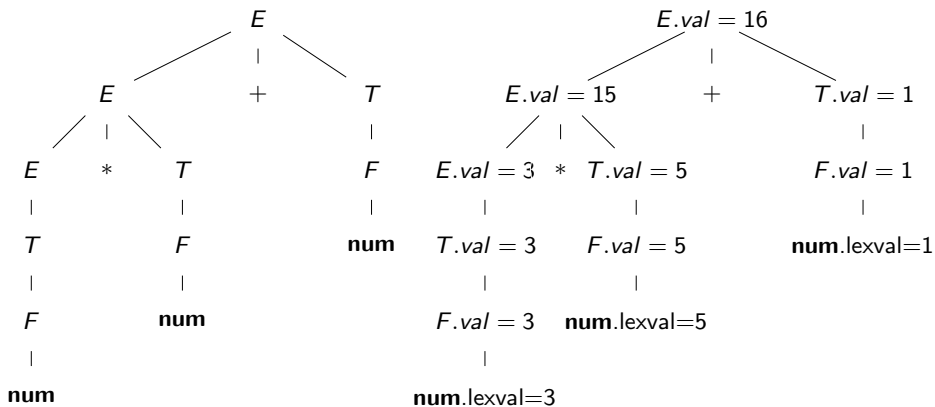
Introduzione

PRODUZIONI	REGOLE SEMANTICHE
$E \rightarrow E + T$	$E.val = E.val + T.val$
$E \rightarrow E - T$	$E.val = E.val - T.val$
$E \rightarrow T$	$E.val = T.val$
$T \rightarrow T * F$	$T.val = T.val * F.val$
$T \rightarrow T / F$	$T.val = T.val / F.val$
$T \rightarrow F$	$T.val = F.val$
$F \rightarrow (E)$	$F.val = E.val$
$F \rightarrow \text{number}$	$F.val = \text{number.lexval}$

Fornire un insieme di regole non è però sufficiente; bisogna anche fornire un ordine di valutazione: e quali regole applicare, e in che ordine, per calcolare il valore in questione

L'ordine di valutazione è definito dall'albero di derivazione per una data stringa

Albero di derivazione (annotato) della stringa $3 * 5 + 1$




Obiettivi

- In questa ultima parte del corso vediamo, in breve, una tecnica che permette di effettuare analisi semantiche e traduzione usando la struttura sintattica data dalla grammatica di un linguaggio
- L'idea chiave è quella di associare, ad ogni costrutto del linguaggio, alcune informazioni utili per il nostro scopo
- L'informazione di ogni costrutto è rappresentata dal valore di diversi **attributi** associati a simboli non terminali della grammatica
- Il valore di ogni attributo è calcolato tramite delle **regole semantiche** associate con le produzioni della grammatica

Due diverse notazioni

- Esistono due diversi formalismi per definire le regole semantiche: **definizioni guidate dalla sintassi** e **schemi di traduzione**
- Le definizioni guidate dalla sintassi sono specifiche di alto livello: nascondono i dettagli implementativi e non richiedono di specificare l'ordine di valutazione che la traduzione deve seguire
- Gli schemi di traduzione, invece, indicano l'ordine in cui le regole semantiche devono essere valutate e quindi permettono la specifica di alcuni dettagli di implementazione
- Noi vedremo soprattutto le definizioni guidate dalla sintassi

Flusso concettuale dei dati



- Dalla stringa di input viene costruito il parse tree, il parse tree viene poi attraversato secondo l'ordine di valutazione delle regole semantiche che si trovano sui nodi
- L'ordine di valutazione delle regole semantiche è definito da un **grafo delle dipendenze**: definisce come attraversare l'albero di derivazione

Definizioni guidate dalla sintassi

- Sono generalizzazioni delle grammatiche in cui **ad ogni simbolo della grammatica è associato un insieme di attributi**
- Gli attributi possono essere di due tipi: **sintetizzati** ed **ereditati**
- Possiamo pensare ad ogni nodo del parse tree come ad un record i cui campi sono i nomi degli attributi
- Ogni attributo può stringhe, numeri, tipi, locazioni di memoria, etc.
- Il valore di ogni attributo ad ogni nodo è determinato da una regola semantica associata alla produzione che si usa nel nodo

Attributi sintetizzati ed ereditati

- Il valore di attributi **sintetizzati** di un dato nodo n è calcolato a partire dai valori degli **attributi dei nodi figli** di n
- Il valore di attributi **ereditati** di un dato nodo n è calcolato a partire dai valori degli attributi dei **nodi fratelli** e del **nodo padre** di n

Attributi sintetizzati: un esempio

L'attributo *val* per la grammatica delle espressioni è un tipico esempio di attributo sintetizzato

PRODUZIONI	REGOLE SEMANTICHE
$E \rightarrow E + T$	$E.val = E.val + T.val$
$E \rightarrow E - T$	$E.val = E.val - T.val$
$E \rightarrow T$	$E.val = T.val$
$T \rightarrow T * F$	$T.val = T.val * F.val$
$T \rightarrow T / F$	$T.val = T.val / F.val$
$T \rightarrow F$	$T.val = F.val$
$F \rightarrow (E)$	$F.val = E.val$
$F \rightarrow \mathbf{number}$	$F.val = \mathbf{number.lexval}$

Attributi ereditati: un esempio

- Un attributo ereditato può essere usato per distribuire informazioni sul tipo fra i vari identificatori di una dichiarazione
- Una dichiarazione è costituita (in molti linguaggi di programmazione: C, Java, ...) da un identificatore di tipo T seguito da una lista L di identificatori

PRODUZIONI	REGOLE SEMANTICHE
$D \rightarrow T L$	$L.type := T.type$
$T \rightarrow \mathbf{int}$	$T.type = \mathbf{int}$
$T \rightarrow \mathbf{real}$	$T.type = \mathbf{real}$
$L \rightarrow L_1, \mathbf{id}$	$L_1.type = L.type$ $\text{addtype}(\text{id.entry}, L.type)$
$L \rightarrow \mathbf{id}$	$\text{addtype}(\text{id.entry}, L.type)$

Attributi ereditati: un esempio

- L'attributo **type** è sintetizzato per T ed ereditato per L
- Inizialmente il valore di **type** è passato da T ad L (mediante la regola **$L.type := T.type$**)
- Durante la costruzione della lista ogni elemento passa al successivo il valore di **type** (mediante la regola **$L_1.type = L.type$**)
- La procedura **addtype**, data un'entrata per la tabella dei simboli per un qualche identificatore (**$id.entry$**) ed un tipo (**$L.type$**), aggiunge al record corrente informazioni riguardo il tipo

Dipendenze tra attributi

- Le regole semantiche inducono delle dipendenze tra il valore degli attributi che possono essere rappresentate con dei grafi (delle dipendenze)
- La valutazione, nel giusto ordine, delle regole semantiche determina il valore per tutti gli attributi dei nodi del parse tree di una stringa data
- La valutazione può avere anche side-effects (effetti collaterali) come la stampa di valori o l'aggiornamento di una variabile globale
- Un parse tree che mostri i valori degli attributi ad ogni nodo è detto **parse tree annotato**
- Il processo di calcolo di questi valori si dice **annotazione** o **decorazione del parse tree**

Forma di una definizione

- È una grammatica libera da contesto estesa in cui ogni produzione $A \rightarrow \alpha$ ha associato un insieme di regole semantiche della forma

$$b ::= f(c_1, c_2, \dots, c_k)$$

dove f è una funzione (di solito espressa con delle espressioni) e b, c_1, c_2, \dots, c_k sono degli attributi

- Se b è un attributo sintetizzato di A allora c_1, c_2, \dots, c_k sono attributi dei simboli in α (figli di b)
- Se b è un attributo ereditato di un di simbolo di α allora c_1, c_2, \dots, c_k sono attributi di simboli di α oppure di A (fratelli e padre di b)
- In ogni caso l'attributo b **dipende dagli attributi** c_1, c_2, \dots, c_k

Un esempio

Le regole semantiche possono avere degli effetti collaterali espressi mediante chiamate di procedura o frammenti di codice

Produzioni	Reg. Semantiche
$L \rightarrow E\mathbf{n}$	<code>println(E.val);</code>
$E \rightarrow E_1 + T$	<code>E.val = E₁.val \oplus T.val</code>
$E \rightarrow T$	<code>E.val = T.val</code>
$T \rightarrow T_1 * F$	<code>T.val = T₁.val \otimes F.val</code>
$T \rightarrow F$	<code>T.val = F.val</code>
$F \rightarrow (E)$	<code>F.val = E.val</code>
$F \rightarrow \mathbf{num}$	<code>F.val = num.lexval</code>

Un esempio

- La grammatica genera le espressioni aritmetiche tra cifre seguite dal carattere **n** di newline
- Ogni simbolo non terminale ha un **attributo sintetizzato** **val**
- Il simbolo terminale **num** ha un attributo sintetizzato **lexval** il cui valore è fornito dall'analizzatore lessicale
- La regola associata al simbolo iniziale L è una chiamata di procedura che stampa un valore intero (side-effect) mentre tutte le altre regole servono per il calcolo del valore degli attributi

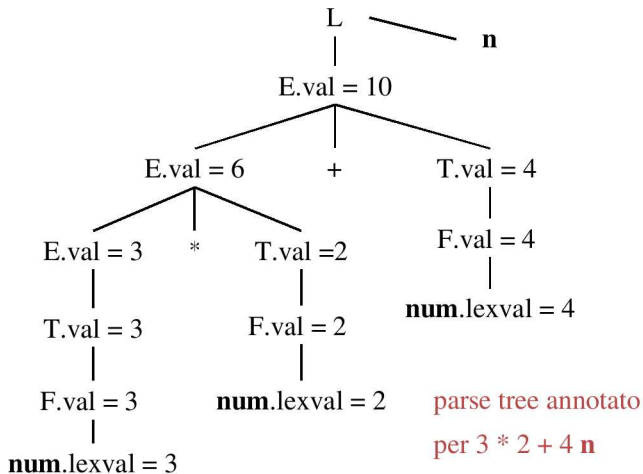
Assunzioni e convenzioni:

- I simboli terminali hanno solo attributi sintetizzati, i cui valori sono, in genere, forniti dall'analizzatore lessicale
- Il simbolo iniziale, se non diversamente specificato, non ha attributi ereditati

Definizioni S-attributed

- In pratica gli attributi sintetizzati sono i più usati
- Una definizione che usa solo attributi sintetizzati è detta **S-attributed**
- Un parse tree di una definizione S-attributed può sempre essere annotato valutando le regole semantiche per gli attributi in maniera bottom-up (dalle foglie alla radice)
- Possono quindi essere implementate facilmente durante il parsing LR
- Generatori automatici di LR-parser possono essere modificati per implementare una definizione S-attributed basata su una grammatica LR

Valutazione degli attributi in unq definizione S-attributed



Valutazione degli attributi in unq definizione S-attributed

- Consideriamo il nodo interno più in basso e più a sinistra per cui è usata la produzione $F \rightarrow \mathbf{num}$
- Dato che il valore dell'attributo **lexval** del nodo figlio **num** è 3, la corrispondente regola semantica $F.val := num.lexval$ pone l'attributo **val** per F a 3
- Allo stesso modo nel nodo padre il valore di **T.val** è 3 (si applica la regola semantica $T.val := F.val$)
- Consideriamo il nodo con la produzione $T \rightarrow T * F$
- La regola semantica è $T.val := T_1.val \otimes F.val$; il \otimes è il corrispondente semantico dell'operatore sintattico $*$ (una possibile implementazione della moltiplicazione fra interi)
- **T₁.val** è il valore dell'attributo **lexval** del primo figlio (quello più a sinistra) T , cioè 3


Attributi ereditati: un esempio

- Questa procedura non può essere utilizzata nel caso in cui la definizione (guidata dalla sintassi) contiene anche qualche attributo ereditato
- Consideriamo la definizione per le dichiarazioni

PRODUZIONI	REGOLE SEMANTICHE
$D \rightarrow T L$	$L.type := T.type$
$T \rightarrow \mathbf{int}$	$T.type = \mathbf{int}$
$T \rightarrow \mathbf{real}$	$T.type = \mathbf{real}$
$L \rightarrow L_1, \mathbf{id}$	$L_1.type = L.type$ $addtype(id.entry, L.type)$
$L \rightarrow \mathbf{id}$	$addtype(id.entry, L.type)$

Parse tree annotato per **real** id_1, id_2, id_3

- Questa procedura non può essere utilizzata nel caso in cui la definizione (guidata dalla sintassi) contiene anche qualche attributo ereditato
- Consideriamo la definizione per le dichiarazioni



Grafi delle dipendenze

- Se un attributo b in un nodo dipende da un attributo c allora la regola semantica per b deve essere valutata dopo la regola semantica che definisce c
- Le interdipendenze fra gli attributi ereditati e sintetizzati nei nodi di un parse tree possono essere agevolmente rappresentate da grafi (delle dipendenze)

Costruzione dei grafi delle dipendenze

- Prima di tutto rendiamo uniformi le regole semantiche ponendole tutte nella forma $b := f(c_1, c_2, \dots, c_k)$
- Per le chiamate di procedure introduciamo un attributo fittizio, ad esempio la regola `addtype(id.entry, L.type)` può essere riscritta come $b_{fitt} := \text{addtype}(\text{id.entry}, \text{L.type})$
- Il grafo ha un nodo per ogni attributo e un arco da c a b se l'attributo b dipende dal valore dell'attributo c

Algoritmo


```
for each nodo  $n$  nel parse tree do  
    for each attributo  $a$  del nodo  $n$  do  
        costruisci un nodo per  $a$  nel grafo;  
  
for each nodo  $n$  nel parse tree do  
    for each regola semantica  $b := f(c_1, c_2, \dots, c_k)$  associata  
        con una produzione usata in  $n$  do  
        for  $i := 1$  to  $k$  do  
            aggiungi un arco dal nodo per  $c_i$  al nodo per  $b$ 
```

Algoritmo

- $A \rightarrow X Y$ con regola semantica associata $A.a := f(X.x, Y.y)$
- L'attributo sintetizzato a associato al non terminale A dipende dagli attributi x ed y di X ed Y risp.
- Se questa produzione è usata nel parse tree allora nel grafo ci sono tre nodi (uno per a , uno per x ed uno per y) e due archi: uno da x ad a e l'altro da y ad a
- $A \rightarrow X Y$ con regola semantica associata $X.x := g(A.a, Y.y)$
- L'attributo ereditato a associato al non terminale X dipende dagli attributi a ed y di A ed Y risp.
- Se questa produzione è usata nel parse tree allora nel grafo ci sono tre nodi (uno per a , uno per x ed uno per y) e due archi: uno da a ad x e l'altro da y ad x

Algoritmo


- Ad esempio, la produzione $E \rightarrow E_1 + T$ con regola semantica $E.val = E_1.val \oplus T.val$ da origine al seguente frammento di grafo



● *nodo del grafo delle dipendenze*

→ *arco del grafo delle dipendenze*

Esempio



Ordine di valutazione

- Un **ordinamento topologico** di un grafo diretto aciclico è un qualsiasi ordinamento dei nodi $n_1 \preceq n_2 \preceq \dots \preceq n_k$ tale che se esiste un arco nel grafo dal nodo n_i al nodo n_j (se la coppia $(n_i, n_j) \in A$) allora n_i precede n_j nell'ordinamento ($n_i \preceq n_j$) ogni coppia i, j
- Nell'esempio precedente l'ordinamento definito dai numeri associati ai nodi $1 \preceq 2 \preceq \dots \preceq 10$ è un ordinamento topologico: se esiste un arco dal nodo i al nodo j allora $i \preceq j$
- Un qualsiasi ordinamento topologico del grafo delle dipendenze dà un ordine valido in cui le regole semantiche possono essere valutate
- Nell'ordinamento topologico i valori degli attributi c_1, c_2, \dots, c_k di una regola $b := f(c_1, c_2, \dots, c_k)$ sono disponibili sempre prima che f sia valutata

Ordine di valutazione

La traduzione specificata da una qualsiasi definizione guidata dalla sintassi può essere sempre e comunque implementata nel seguente modo:

- 1 si costruisce il parse tree
- 2 si costruisce il grafo delle dipendenze
- 3 si trova un ordinamento topologico del grafo
- 4 si valutano le regole semantiche dei nodi secondo l'ordinamento

Ordine di valutazione



Consideriamo di nuovo il solito esempio, la valutazione della dichiarazione *real* d_1, d_2, d_3 . Abbiamo: (1) costruito il parse tree dalla stringa, (2) costruito il grafo delle dipendenze e (3) identificato un ordinamento topologico del grafo. Non ci resta che valutare le regole semantiche in base all'ordinamento, ottenendo il seguente frammento di codice:

```
 $a_4 := \text{real};$   
 $a_5 := a_4;$   
 $\text{addtype}(id_3.\text{entry}, a_5);$   
 $a_7 := a_5;$   
 $\text{addtype}(id_2.\text{entry}, a_7);$   
 $a_9 := a_7;$   
 $\text{addtype}(id_1.\text{entry}, a_9);$ 
```

Syntax Tree

- Vediamo ora come sia possibile usare le definizioni guidate dalla sintassi per specificare (implementare) la costruzione di syntax tree
- Abbiamo parlato di syntax tree all'inizio del corso: un albero sintattico (astratto) è una forma condensata di un parse tree che è utile per rappresentare i costrutti dei linguaggi
- Operatori e le parole chiave non appaiono come foglie, ma sono associati a nodi interni; sulle foglie troviamo invece gli operandi
- Un'altra semplificazione è che le catene di applicazione di una singola produzione vengono collassate

Syntax Tree



Alcuni esempi di Syntax Tree

- La traduzione guidata dalla sintassi potrebbe essere basata su alberi sintattici piuttosto che su parse tree
- L'approccio è sempre lo stesso: associamo degli attributi ai nodi dell'albero

Costruzione di Syntax Tree

- Vediamo ora in dettaglio come costruire gli alberi sintattici per le espressioni aritmetiche; la procedura è chiaramente ricorsiva
- Costruiamo, innanzitutto, i sottoalberi per le sottoespressioni creando un nodo per ogni operatore ed operando
- I figli di un nodo operatore altro non sono che le radici dei sottoalberi che rappresentano le sottoespressioni che definiscono l'espressione principale
- Ogni nodo di un syntree può essere implementato mediante un record con diversi campi

Costruzione di Syntax Tree

- In un **nodo operatore** un campo identifica l'operatore stesso e i campi rimanenti sono i puntatori ai nodi operandi; l'operatore è spesso detto **etichetta** del nodo
- I nodi in un syntree possono avere campi aggiuntivi per gli attributi che sono stati definiti
- In un **nodo operando** un campo identifica l'operando che può essere un identificatore o un numero
- I campi rimanenti possono rappresentare un'entrata alla symbol table (nel caso in cui l'operando sia un identificatore) o un valore (nel caso in cui l'operando sia un numero)

Costruzione di Syntax Tree


Usiamo le seguenti funzioni per costruire i nodi dei syntree per espressioni con operatori **binari**:

- 1 *mknode*(*op*, *left*, *right*) crea un nodo operatore con etichetta *op* e due campi puntatore all'operando destro e sinistro
- 2 *mkleaf*(*id*, *entry*) crea un nodo identificatore con etichetta *id* ed un puntatore *entry* alla tabella dei simboli
- 3 *mkleaf*(*num*, *val*) crea un nodo numero con etichetta *num* e un campo *val* contenente il valore

Costruzione di Syntax Tree

Il seguente frammento di programma crea (in maniera bottom-up) un syntax tree per l'espressione $a - 4 + c$

1. $p_1 = \text{mkleaf}(\mathbf{id}, \text{entry}_a);$
2. $p_2 = \text{mkleaf}(\mathbf{num}, 4);$
3. $p_3 = \text{mknode}('-', p_1, p_2);$
4. $p_4 = \text{mkleaf}(\mathbf{id}, \text{entry}_c);$
5. $p_3 = \text{mknode}('+', p_3, p_4);$



Usiamo una definizione

- Diamo una definizione guidata dalla sintassi S-attributed per la costruzione dell'albero sintattico di una espressione contenente gli operatori $+$ e $-$
- Introduciamo un attributo *nptr* per ogni simbolo non terminale
- Esso deve tenere traccia dei puntatori ritornati dalle funzioni di creazione dei nodi

Produzioni	Regole Semantiche
$E \rightarrow E_1 + T$	$E.nptr := mknode('+', E_1.nptr, T.nptr)$
$E \rightarrow E_1 - T$	$E.nptr := mknode('-', E_1.nptr, T.nptr)$
$E \rightarrow T$	$E.nptr := T.nptr$
$T \rightarrow (E)$	$T.nptr := E.nptr$
$T \rightarrow \text{num}$	$E.nptr := mkleaf(id, id.entry)$
$T \rightarrow id$	$E.nptr := mkleaf(num, num.val)$

Albero annotato

